

语言模型是无监督多任务学习者

Alec Radford^{*1} Jeffrey Wu^{*1} Rewon Child¹ David Luan¹ Dario Amodei^{**1} Ilya Sutskever^{**1}

摘要

自然语言处理任务（如问答、机器翻译、阅读理解与摘要生成）通常采用针对特定任务数据集的监督学习方法。我们证明，当在名为 WebText 的包含数百万网页的新数据集上训练时，语言模型无需任何显式监督即可开始学习这些任务。当以文档加问题为条件时，语言模型生成的答案在 CoQA 数据集上达到 55 F1 分数——匹配或超越了四个基线系统中三个的表现，且未使用那 127,000 多个训练样本。语言模型的容量对零样本任务迁移的成功至关重要，增加其容量可使各项任务性能呈对数线性提升。我们最大的模型 GPT-2 是一个含 15 亿参数的 Transformer 模型，在零样本设置下于所测试的 8 个语言建模数据集上的 7 个上达到当前最优结果，但仍未能充分拟合 WebText。该模型生成的样本体现了这些改进，包含连贯的文字段落。这些发现表明，一条有望构建语言处理系统的新路径正在浮现——这类系统可从自然发生的任务演示中学习执行任务。

1. 引言

当前机器学习系统凭借大规模数据集、高容量模型与监督学习的结合，在其训练任务上（期望意义上）表现出色（Krizhevsky 等人，2012）（Sutskever 等人，2014）（Amodei 等人，2016）。然而，这些系统十分脆弱，对数据分布的细微变化（Recht 等人，2018）及任务规范的细微调整（Kirkpatrick 等人，2017）极为敏感。当前系统更宜被刻画为窄域专家，而非

胜任的通才。我们希望迈向更具通用性的系统，使其能够执行多种任务——最终无需为每一项任务手动创建并标注训练数据集。

构建机器学习系统的主流方法是：收集一组展现所需任务正确行为的训练样本，训练系统模仿这些行为，再于独立同分布（IID）的保留样本上测试其性能。该方法在推进窄域专家系统方面成效显著。但图像标注模型（Lake 等人，2017）、阅读理解系统（Jia & Liang，2017）及图像分类器（Alcorn 等人，2018）在面对输入多样性与丰富性时表现出的不稳定行为，凸显了该方法的部分缺陷。

我们推测，单一领域数据集上的单任务训练是导致当前系统泛化能力不足的主要原因之一。要在现有架构下取得鲁棒系统的进展，很可能需要在广泛领域与任务上进行训练与性能评估。近期已提出若干基准测试，例如 GLUE（Wang 等人，2018）与 decaNLP（McCann 等人，2018），以开启相关研究。多任务学习（Caruana，1997）是提升整体性能的有前景框架。然而，自然语言处理中的多任务学习

仍处于起步阶段。近期工作报告了有限的性能提升（Yogatama 等人，2019），迄今两项最具雄心的努力分别仅在总计 10 组与 17 组（数据集，目标）组合上进行了训练（McCann 等人，2018）（Bowman 等人，2018）。从元学习视角看，每组（数据集，目标）组合即是从数据集与目标分布中采样的一个单独训练样本。当前机器学习系统需要数百至数千个样本才能归纳出具有良好泛化能力的函数。这表明，要充分发挥多任务学习的潜力，当前方法可能同样需要大量有效的训练组合。而持续扩大数据集创建与目标设计的规模，以期凭借现有技术强行达成此目标，将极其困难。因此，探索多任务学习的其他可行设定势在必行。

*、** 同等贡献 1OpenAI，美国加利福尼亚州旧金山。通讯作者：Alec Radford <alec@openai.com>。

当前在语言任务上性能最佳的系统




图1. WebText 语言模型在多项自然语言处理任务上的零样本任务性能随模型规模的变化关系。阅读理解结果基于 CoQA (Reddy 等人, 2018), 翻译结果基于 WMT-14 法英数据集 (Artetxe 等人, 2017), 摘要结果基于 CNN 和 Daily Mail (See 等人, 2017), 问答结果基于 Natural Questions (Kwiatkowski 等人, 2019)。第3节详细描述各项结果。

采用预训练与监督微调相结合的方式。该方法历史悠久, 且呈现出向更灵活迁移形式发展的趋势: 最初学习词向量并将其用作任务特定架构的输入 (Mikolov 等人, 2013) (Collobert 等人, 2011); 随后迁移循环网络的上下文表征 (Dai & Le, 2015) (Peters 等人, 2018); 近期研究表明, 任务特定架构已非必需, 仅迁移多个自注意力模块即已足够 (Radford 等人, 2018) (Devlin 等人, 2018)。这些方法仍需监督训练才能执行任务。当仅有极少甚至无监督数据可用时, 另一研究方向已证明语言模型在执行特定任务 (如常识推理 (Schwartz 等人, 2017) 与情感分析 (Radford 等人, 2017)) 方面的潜力。

本文将这两条研究脉络联系起来, 并延续更通用迁移方法的发展趋势。我们证明语言模型可在零样本设置下执行下游任务——无需任何参数或架构修改。我们通过突出语言模型在零样本设置下执行广泛任务的能力, 展示了该方法的潜力。依据具体任务, 我们取得了富有希望、具竞争力及当前最优的结果。

2. 方法

我们方法的核心是语言建模。语言建模通常被构想为从一组样本 $(x, x, \dots, x)$ 中进行无监督分布估计, 其中每个样本均由可变长度的符号序列 $(s, s, \dots, s)$ 构成。由于语言具有天然的顺序性, 通常将联合概率按顺序分解为

符号表示为条件概率乘积 (Jelinek & Mercer, 1980) (Bengio 等人, 2003):

$$p(x) = \prod_{i=1}^n p(s_i | s_1, \dots, s_{i-1}) \quad (1)$$

该方法使得对 $p(x)$ 及任意形如 $p(s, \dots, s | s_1, \dots, s_n)$ 的条件分布进行可行采样与估计成为可能。近年来, 能够计算此类条件概率的模型表达能力显著提升, 例如基于自注意力机制的 Transformer 架构 (Vaswani 等人, 2017)。

学习执行单个任务可在概率框架中表述为估计条件分布 $p(\text{输出} | \text{输入})$ 。由于通用系统应能执行多种不同任务 (甚至针对同一输入), 因此它不仅需以输入为条件, 还需以待执行任务为条件。即, 它应建模 $p(\text{输出} | \text{输入}, \text{任务})$ 。该思想已在多任务学习与元学习等设定中被不同方式形式化。任务条件化常在架构层面实现, 例如 Kaiser 等人 (2017) 提出的任务特定编码器与解码器; 或在算法层面实现, 例如 MAML 的内外循环优化框架 (Finn 等人, 2017)。但如 McCann 等人 (2018) 所示, 语言提供了一种灵活方式, 可将任务、输入与输出全部表示为符号序列。例如, 翻译训练样例可写作序列 (译为法语, 英文文本, 法文文本); 同样, 阅读理解训练样例可写作 (回答问题, 文档, 问题, 答案)。McCann 等人 (2018) 已证明, 可训练单一模型 MQAN,

推断并执行多种不同任务，适用于此类格式的示例。

语言建模原则上也能学习 McCann 等人 (2018) 提出的各项任务，而无需显式监督哪些符号为待预测的输出。由于监督目标函数与无监督目标函数相同，仅在序列的某子集上进行评估，因此无监督目标函数的全局最小值同时也是监督目标函数的全局最小值。在此略带理想化的设定中，Sutskever 等人 (2015) 所讨论的、将密度估计作为原则性训练目标所引发的担忧被规避了。问题转而变为：实践中我们能否将无监督目标函数优化至收敛。初步实验证实，足够大的语言模型确实能在这种略带理想化的设定中执行多任务学习，但学习速度远慢于显式监督方法。虽然从上述定义明确的设定迈向真实世界纷繁复杂的语言是一大步，但 Weston

(2016) 在对话场景下提出，有必要开发能够直接从自然语言中学习的系统，并展示了一项概念验证——即通过前向预测教师输出的方式，在无奖励信号的情况下学习问答任务。尽管对话是一种颇具吸引力的方法，但我们担心其限制性过强。互联网蕴含海量信息，这些信息被动可得，无需交互式通信。我们推测，只要语言模型具备足够容量，便会开始学习推断并执行自然语言序列中所展示的各类任务，从而提升对这些序列的预测能力，而不论其获取方式如何。若语言模型真能实现这一点，则实质上便是在进行无监督多任务学习。我们通过分析语言模型在零样本设置下于多种任务上的表现来检验这一假设。

2.1 训练数据集

此前大多数研究均在单一文本领域（例如新闻文章 (Jozefowicz 等, 2016)、维基百科 (Merity 等, 2016) 或小说 (Kiros 等, 2015)）上训练语言模型。我们的方法旨在构建尽可能大规模、多样化的数据集，以在尽可能广泛的不同领域与情境中收集自然语言形式的任务演示。

一种颇具前景的多样化且近乎无限的文本来源是网络爬取数据，例如 Common Crawl。尽管此类存档的规模比当前的语言建模数据集大若干数量级，但其数据质量存在严重问题。Trinh & Le (2018) 在常识推理研究中使用了 Common Crawl，但指出其中大量文档内容基本无法理解。我们在初始实验中也观察到了类似的数据问题，

我并非世上最聪明的人，但正如法语所说：Je ne suis pas un imbécile（我不是傻瓜）。

在一则已于2017年8月16日删除的帖子中，乔利埃特选区保守党候选人索海尔·艾德用法语写道：Mentez mentez, il en restera toujours quelque chose，意为：“撒谎吧，撒谎吧，总有些东西会留下。”

我讨厌perfume这个词，”伯尔说，“在法语中稍好些：parfum。

若仔细聆听29分55秒处，可听到两名男子用法语交谈：-Comment on fait pour aller de l'autre côté? -Quel autre côté?，意为：-如何到达另一侧? -哪一侧?

如果这听起来有些牵强，请思考下面这个法语问题：As-tu aller au cin'ema? (你去电影院了吗?)，其字面意思是“你去电影/剧院了吗?”

Brevet Sans Garantie Du Gouvernement, 英文译为：专利无政府担保。

表1. WebText训练集中自然出现的英译法、法译英翻译示例。

Common Crawl. Trinh & Le (2018) 的最佳结果基于Common Crawl的一个小规模子样本，该子样本仅包含与其目标数据集 (Winograd Schema挑战赛) 最相似的文档。尽管这是提升特定任务性能的务实方法，但我们希望避免预先对需执行的任务做出假设。

相反，我们构建了一个强调文档质量的新网页爬取数据集。为此，我们仅爬取由人工筛选/过滤过的网页。对整个网页爬取结果进行人工过滤成本极高，因此我们以Reddit（一个社交媒体平台）为起点，爬取其所有获得至少3分karma的出站链接。这可视为一种启发式指标，反映其他用户是否认为该链接有趣、具教育意义或仅令人发笑。

所得数据集WebText包含上述4500万链接的文本子集。为从HTML响应中提取文本，我们结合使用 Dragnet (Peters & Lecocq, 2013) 与 Newspaper1 内容提取器。本文所呈现的所有结果均基于WebText的初步版本，该版本不包含2017年12月之后创建的链接。

2017年，并在去重及部分基于启发式的清洗后，共包含略超800万篇文档，总计40GB文本。我们从WebText中移除了所有维基百科文档，因其是其他数据集的常见数据源，若保留则可能因训练数据与测试任务重叠而干扰分析。

¹<https://github.com/codelucas/newspaper>

训练数据与测试评估任务存在重叠。

2.2. 输入表示

通用语言模型 (LM) 应能计算 (并生成) 任意字符串的概率。当前大规模语言模型包含小写转换、分词及未登录词 (OOV) 等预处理步骤, 限制了可建模字符串的空间。虽然将Unicode字符串视为UTF-8字节序列进行处理可优雅满足此要求 (如Gillick等, 2015的工作所示), 但当前字节级语言模型在One Billion Word Benchmark (Al-Rfou等, 2018) 等大规模数据集上尚无法与词级语言模型竞争。我们在WebText上训练标准字节级语言模型的尝试中也观察到了类似的性能差距。

字节对编码 (BPE) (Sennrich等, 2015) 是介于字符级与词级语言建模之间的实用折中方案, 能有效在高频符号序列上采用词级输入, 在低频符号序列上采用字符级输入。尽管名称如此, 主流BPE实现通常作用于Unicode码点而非字节序列。这类实现需纳入全部Unicode符号空间才能建模所有Unicode字符串, 导致基础词汇表规模在未添加多符号词项前即逾13万。相比BPE常用3.2万至6.4万的词表规模, 此规模显然过大。相较而言, 字节级BPE仅需256大小的基础词汇表。然而, 若直接对字节序列应用BPE, 则因BPE构建词表时采用基于频率的贪心启发式策略, 会导致合并效果欠佳。我们观察到BPE会收录大量常见词 (如dog) 的不同变体 (如dog.、dog!、dog?), 造成有限词汇槽位与模型容量的非最优分配。为避免此问题, 我们禁止BPE对跨字符类别的字节序列进行合并。同时, 我们对空格作例外处理, 此举显著提升了压缩效率, 仅带来极轻微的词语跨多个词表项的碎片化。

这种输入表示方式使我们得以融合词级语言模型的经验优势与字节级方法的普适性。由于我们的方法可为任意Unicode字符串分配概率, 因此无论数据集经历何种预处理、分词或词汇表大小如何, 均可对其语言模型进行评估。

2.3. 模型

我们的语言模型采用基于Transformer (Vaswani等, 2017) 的架构。模型整体沿用OpenAI GPT模型 (Radford等, 2018) 的细节, 但做了

参数量	层数	d_model
1600	12	1600

表2. 四种模型规模的架构超参数。

若干修改: 层归一化 (Ba等, 2016) 移至每个子模块的输入端, 类似于预激活残差网络 (He等, 2016); 最终自注意力块之后额外增加一层归一化。采用一种修正的初始化方法, 考虑残差路径随模型深度累积的影响: 初始化时将残差层权重按 $1/\sqrt{N}$ 缩放, 其中N为残差层数。词汇表扩展至50,257个词项。上下文长度亦从512增至1024个token, 并采用更大的批大小512。

3. 实验

我们训练并评测了四个规模大致呈对数均匀分布的语言模型。各模型架构总结见表2。最小模型等效于原始GPT, 第二小模型等效于BERT (Devlin等, 2018) 中最大的模型。我们最大的模型 (称为GPT-2) 的参数量超过GPT一个数量级。每个模型的学习率均经人工调优, 以在WebText的5%预留样本上获得最佳困惑度。所有模型目前仍未充分拟合WebText, 且预留样本困惑度迄今仍在随训练时间延长而持续改善。

3.1. 语言建模

作为迈向零样本任务迁移的初步尝试, 我们希望了解WebText语言模型在零样本领域迁移方面、针对其主要训练任务——即语言建模——的表现如何。由于我们的模型以字节为单位运行, 无需有损预处理或分词, 因此可在任意语言建模基准上对其进行评估。语言建模数据集的结果通常以某一指标表示, 该指标是每个标准预测单元 (通常为字符、字节或单词) 平均负对数概率的缩放或指数化版本。我们通过计算WebText语言模型对数据集的对数概率, 并除以标准单元数量, 来评估同一指标。对于其中许多数据集, WebText语言模型将面临显著分布外 (out-of-distribution) 的测试场景, 需预测经过严格标准化的文本、分词引入的人工痕迹 (例如孤立标点符号与缩略形式)、被打乱顺序的句子, 甚至字符串

	LAMBADA	LAMBADA	CBT-CN	CBT-NE	WikiText2	PTB	enwik8	text8	WikiText103	1BW
	(困惑度, PPL)	(准确率, ACC)	(准确率, ACC)	(准确率, ACC)	(困惑度, PPL)	(困惑度, PPL)	(每字节比特数, BPB)	(每字节比特数, BPC)	(困惑度, PPL)	(困惑度, PPL)
SOTA	99.8	59.23	85.7	82.3	39.14	46.54	0.99	1.08	18.3	21.8
1.17亿参数	35.13	45.99	87.65	83.4	29.41	65.85	1.16	1.17	37.50	75.20
3.45亿参数	15.60	55.48	92.35	87.1	22.76	47.33	1.01	1.06	26.37	55.72
7.62亿参数	10.87	60.12	93.45	88.0	19.93	40.31	0.97	1.02	22.05	44.575
15.42亿参数	8.63									42.16

表3. 多个数据集上的零样本结果。这些结果均未进行任何训练或微调。PTB和WikiText-2结果来自 (Gong等, 2018) ; CBT结果来自 (Bajgar等, 2016) ; LAMBADA准确率结果来自 (Hoang等, 2018) , LAMBADA困惑度结果来自 (Grave等, 2016) ; 其余结果来自 (Dai等, 2019) 。

<UNK>在WebText中极为罕见——400亿字节中仅出现26次。我们在表3中报告主要重测结果,使用可逆的去分词器 (de-tokenizers) , 尽可能消除这些分词/预处理带来的人工痕迹。由于这些去分词器是可逆的, 我们仍可计算数据集的对数概率, 它们也可视作一种简单的领域自适应形式。使用这些去分词器后, GPT-2的困惑度 (perplexity) 降低了2.5至5。

WebText语言模型 (LM) 在不同领域和数据集之间迁移效果良好, 在零样本 (zero-shot) 设置下, 于8个数据集上的7个上刷新了当前最优水平 (state of the art) 。在Penn Treebank和WikiText-2等小型数据集 (仅含100万至200万个训练token) 上, 提升尤为显著。在专为衡量长程依赖性而构建的数据集 (如LAMBADA (Paperno等, 2016) 和儿童图书测试 (Hill等, 2015)) 上, 同样观察到大幅改进。然而, 我们的模型在 One Billion Word Benchmark (Chelba等, 2013) 上的表现仍明显逊于先前工作。这很可能源于该数据集既是规模最大的, 又经历了最具破坏性的预处理——1BW数据集中句子级别的随机打乱彻底消除了所有长程结构。

3.2. 儿童图书测试




图2. 儿童图书测试 (Childrens Book Test) 上的性能随模型容量变化的情况。人类表现数据来自 Bajgar 等人 (2016) , 而非原始论文中低得多的估计值。

儿童图书测试 (CBT) (Hill等, 2015) 旨在考察语言模型在不同词类 (专有名词、名词、动词与介词) 上的表现。CBT并未采用困惑度作为评估指标, 而是报告一种自动构建的完形填空测试的准确率, 任务是从10个可能选项中预测被省略词的正确答案。我们遵循原始论文中提出的语言模型方法, 根据语言模型计算每个选项及其后句子的概率, 并选择概率最高的选项作为预测结果。如图2所示, 随着模型规模增大, 性能持续提升, 并大幅缩小了与人类在此测试中表现的差距。数据重叠分析显示, CBT测试集中的一本书——吉卜林的《丛林之书》——出现在WebText中, 因此我们报告无显著重叠的验证集结果。GPT-2在常见名词上达到93.3%的新当前最优准确率, 在专有名词上达89.1%。我们应用了去分词器, 以消除CBT中宾州树库 (PTB) 风格分词所引入的人工痕迹。

3.3 LAMBADA

LAMBADA数据集 (Paperno等, 2016) 用于检验系统建模文本长程依赖关系的能力。其任务是预测句子的最后一个词, 而人类需至少50个词元的上下文才能成功预测。GPT-2将当前最优困惑度从99.8 (Grave等, 2016) 降至8.6, 并将语言模型在此测试中的准确率从19% (Dehghani等, 2018) 提升至52.66%。对GPT-2错误的分析显示, 多数预测均为句子的有效延续, 但并非正确的句末词。这表明该语言模型尚未充分利用 ‘该词必须为句末词’ 这一额外有用约束。加入停用词过滤器作为对此约束的近似处理, 可进一步将准确率提升至63.24%, 使该任务的整体当前最优水平提高4%。此前的当前最优方案 (Hoang等, 2018) 采用了不同的受限预测设定, 即模型输出仅限于上下文中出现过的词语; 而对GPT-2而言, 此类限制反而有害而非有益。

因为19%的答案不在上下文中。我们使用未经预处理的该数据集版本。

3.4 Winograd模式挑战赛




图3: Winograd模式挑战赛表现随模型容量变化的趋势

Winograd模式挑战赛 (Levesque等, 2012) 旨在通过测量系统解析文本歧义的能力, 来评估其常识推理能力。近期Trinh与Le (2018) 利用语言模型在此挑战中取得显著进展, 方法是更高概率地预测歧义解析结果。我们沿用其问题设定, 并在图3中以全分与部分评分两种技术展示各模型的表现。GPT-2将当前最优准确率提升7%, 达70.70%。该数据集样本量极小, 仅含273个实例, 因此我们建议参阅Trichelair等 (2018) 的研究以更好理解这一结果。

3.5 阅读理解

对话问答数据集 (CoQA) (Reddy等, 2018) 包含来自7个不同领域的文档, 以及围绕这些文档展开的提问者与回答者之间的自然语言对话。CoQA既测试阅读理解能力, 也测试模型回答依赖对话历史 (例如‘为什么?’) 的问题的能力。

当GPT-2在给定文档、相关对话历史及最终标记‘A:’的条件下进行贪心解码时, 在开发集上达到55 F1分。该成绩匹配或超越了4个基线系统中3个的表现, 且未使用这些基线系统所依赖的逾12.7万个手工标注问答对。当前监督学习最优方案为基于BERT的系统 (Devlin等,

	R-1	R-2	R-L	R-AVG
Bottom-Up Sum	41.22	18.68	38.34	32.75
Lede-3	40.38	17.66	36.62	31.55
Seq2Seq + Attn	31.33	11.81	28.83	23.99
GPT-2 TL;DR:	29.34	8.27	26.58	21.40
Random-3	28.78	8.63	25.52	20.98
GPT-2 no hint	21.58	4.03	19.47	15.03

表4: 在CNN与《每日邮报》数据集上以ROUGE F1指标衡量的摘要生成性能。Bottom-Up Sum为Gehrmann等 (2018) 提出的当前最优模型

2018) 已接近人类89 F1分的表现。尽管GPT-2在未经任何监督训练的情况下取得如此性能令人振奋, 但对其答案与错误的细致考察表明, GPT-2常采用基于简单检索的启发式策略, 例如在回答‘谁’类问题时直接从文档中提取一个人名作为答案。

3.6 摘要生成

我们在CNN与《每日邮报》数据集 (Nallapati等, 2016) 上测试GPT-2的摘要生成能力。为引导模型执行摘要任务, 我们在文章末尾添加文本‘TL;DR:’, 并以Top-k随机采样 (k=2) (Fan等, 2018) 生成100个词元, 此举可减少重复、鼓励比贪心解码更具抽象性的摘要。我们从这100个词元中选取最先生成的3个句子作为摘要。尽管这些生成内容在定性上类似摘要 (见表14), 但往往聚焦于文章中较新近的内容, 或混淆某些具体细节, 例如事故中涉及几辆汽车, 或标志出现在帽子上还是衬衫上。在常用的ROUGE-1、ROUGE-2与ROUGE-L指标下, 生成摘要的表现仅开始接近经典神经基线模型, 勉强优于从文章中随机选取3个句子。当移除任务提示时, GPT-2在综合指标上的表现下降6.4分, 表明可通过自然语言提示在语言模型中激发特定任务行为。

3.7 翻译

我们测试GPT-2是否已开始学习如何在两种语言之间进行翻译。为帮助其推断这是所需任务, 我们将语言模型置于若干英文句子=法文句子格式的样例对构成的上下文中, 并在最终提示‘英文句子=’之后, 采用贪心解码方式从模型中采样, 将生成的第一个句子作为翻译结果。在WMT-14英法测试集上, GPT-2获得5 BLEU分数, 略低于此前关于无监督词翻译工作中所推断出的双语词典逐词替换效果。

问题	生成答案	正确概率
《物种起源》一书的作者是谁？	查尔斯·达尔文	✓ 83.4%
Ubuntu项目的创始人是谁？	马克·沙特尔沃思	✓ 82.0%
绿湾包装工队的四分卫是谁？	阿隆·罗杰斯	✓ 81.1%
熊猫是哪个国家的国宝？	中国	✓ 76.8%
相对论由谁提出？	阿尔伯特·爱因斯坦	✓ 76.4%
第一部《星球大战》电影何时上映？		✓ 71.4%
瑞典最常见的血型是什么？		✗ 70.6%
谁被公认为精神分析学的创始人？	西格蒙德·弗洛伊德	✓ 69.3%
1969年谁首次踏上月球？	尼尔·阿姆斯特朗	✓ 66.8%
英国规模最大的连锁超市是哪家？	乐购	✓ 65.3%
‘shalom’在英语中的含义是什么？	和平	✓ 64.0%
《孙子兵法》的作者是谁？	孙子	✓ 59.6%
美国陆地面积最大的州是哪一个？	加利福尼亚州	✗ 59.2%
绿藻属于哪一类繁殖方式的示例？	孤雌生殖	✗ 56.5%
维克拉姆历在哪个国家是官方历法？	印度	✓ 55.6%
《独立宣言》主要由谁起草？	托马斯·杰斐逊	✓ 53.3%
与蒙大拿州西界接壤的是美国哪个州？	蒙大拿州	✗ 52.3%
《权力的游戏》中戴佛斯爵士由谁扮演？	彼特·丁拉基	✗ 52.1%
谁任命美联储主席？	珍妮特·耶伦	✗ 51.5%
阐述将一个细胞核分裂为两个遗传物质完全相同细胞核的过程？有丝分裂		✓ 50.7%
NBA历史上获得最多常规赛最有价值球员（MVP）奖项的是谁？	迈克尔·乔丹	✗ 50.2%
与罗马城相关的河流是哪一条？	台伯河	✓ 48.6%
首位遭弹劾的美国总统是谁？	安德鲁·约翰逊	✓ 48.3%
2017年美国国土安全部部长是谁？	约翰·凯利	✓ 47.0%
欧盟通用货币的名称是什么？	欧元	✓ 46.8%
《星球大战》中皇帝的名字是什么？	帕尔帕廷	✓ 46.5%
去射击场打靶是否需要持枪许可证？	否	✓ 46.4%
谁于1859年提出进化论作为生物发展的基础？	查尔斯·达尔文	✓ 45.7%
俄罗斯发生爆炸的核电站？	切尔诺贝利	✓ 45.7%
谁在原版《终结者》中饰演约翰·康纳？	阿诺德·施瓦辛格	✗ 45.2%

表5. GPT-2在Natural Questions开发集上生成的置信度最高的30个答案，按GPT-2所赋概率排序。依据第4节所述流程，这些问题均未出现在WebText中。

(Conneau等, 2017b)。在WMT-14法英测试集上，GPT-2可充分利用其极为强大的英语语言模型，显著提升性能，达到11.5 BLEU分。这一结果优于Artetxe等 (2017) 及Lample等 (2017) 提出的若干无监督机器翻译基线方法，但仍远逊于当前最佳无监督机器翻译方法 (Artetxe等, 2019) 的33.5 BLEU分。我们在该任务上的表现令我们颇感意外，因为我们曾刻意在WebText预处理阶段剔除所有非英语网页。为确认此点，我们使用字节级语言检测器²对WebText进行扫描，仅检测到约10MB法语数据，其规模约为先前无监督机器翻译研究中常用单语法语语料库的1/500。

3.8. 问答任务

检验语言模型内含信息的一种潜在方式，是评估其生成事实型问题正确答案的频率。此前神经网络系统（如Vinyals与Le于2015年提出的《神经对话模型》，其全部信息均存储于参数中）对该行为的展示，因缺乏高质量评测数据集而仅能提供定性结果。近期发布的Natural Questions数据集 (Kwiatkowski等,

2019) 是定量检验该现象的有力资源。与翻译任务类似，语言模型的上下文通过示例问答对进行初始化，有助于模型推断该数据集所需的简短答案风格。GPT-2在阅读理解类数据集（如SQUAD）常用的精确匹配指标下，正确回答了4.1%的问题。³ 作为参照，最小规模模型的表现甚至未超过一种极其简单的基线方法——该方法针对每类问题（谁、什么、哪里等）均返回最常见答案，其准确率仅为1.0%。GPT-2正确回答的问题数量是该基线的5.3倍，表明模型容量至今仍是神经网络系统在此类任务中表现欠佳的主要因素。GPT-2为其生成答案所分配的概率校准良好；在它置信度最高的1%问题上，其准确率达63.1%。GPT-2在开发集问题上生成的置信度最高的30个答案见表5。GPT-2的表现仍远逊于融合信息检索与抽取式文档问答的开放域问答系统 (Alberti等, 2019)，后者的准确率范围为30%至50%。

³ 阿莱克此前自认擅长随机 trivia 类问题，在与GPT-2相同的测试环境下随机抽取100个样例作答，仅正确回答17题。实际上他仅答对14题，但其本应答对另外3题

²<https://github.com/CLD2Owners/cld2>

	PTB	WikiText-2	enwik8	text8	Wikitext-103	1BW
数据集 训练集	2.67%	0.66%	7.50%	2.34%	9.09%	13.19%
WebText训练集	0.88%	1.63%	6.31%	3.94%	2.42%	3.75%

表6. 测试集8-gram与训练集重叠百分比。

4. 泛化能力 vs 记忆能力

计算机视觉领域的近期研究表明，常用图像数据集包含相当数量的近似重复图像。例如，CIFAR-10数据集中训练图像与测试图像之间存在3.3%的重叠（Barz & Denzler, 2019）。这导致机器学习系统泛化性能被高估。随着数据集规模增大，此类问题愈发普遍，暗示WebText也可能存在类似现象。因此，分析测试数据在多大程度上亦出现于训练数据中至关重要。

为开展此项研究，我们构建了包含WebText训练集词元8-gram的布隆过滤器。为提升召回率，字符串经标准化处理，仅保留小写英文字母数字单词，并以单个空格作为分隔符。布隆过滤器的构造确保其误报率上限为 $1/10^8$ 。我们进一步通过生成100万个字符串进行验证，结果无一被该过滤器误判为存在。

这些布隆过滤器使我们能够计算：给定某个数据集，该数据集中有多少比例的8-gram也出现在WebText训练集中。表6展示了常见语言模型基准测试集的此类重叠分析结果。常见语言模型数据集的测试集与WebText训练集的重叠率介于1%至6%之间，平均重叠率为3.2%。出人意料的是，许多数据集与其自身训练划分的重叠率更高，平均重叠率达5.9%。

我们的方法以召回率为优化目标；尽管人工检查重叠内容显示其中包含大量常见短语，但许多更长的匹配实则源于重复数据。这并非WebText独有现象。例如，我们发现WikiText-103测试集中有一篇文章同样出现在其训练数据集中。由于测试集仅含60篇文章，因此重叠率至少达1.6%。⁴更令人担忧的是，根据我们的检测流程，1BW与其自身训练集的重叠率接近13.2%。

对于Winograd模式挑战赛（WSC），我们仅发现10个模式与WebText训练集存在至少一个8-gram重叠。其中2个为虚假匹配。剩余8个模式中，仅有1个模式出现在任何上下文中，

⁴A 额外重叠中相当大一部分源于编辑人员在多个主题相同的文章（例如朝鲜战争中的若干战役）中重复使用某些段落。

泄露了答案。

对于CoQA数据集，新闻领域中约15%的文档已存在于WebText中，模型在这些文档上的表现F1值高出约3分。CoQA的开发集指标报告了五个不同领域的平均性能，我们测得各领域间因数据重叠带来的增益约为0.5–1.0 F1分。然而，由于CoQA的发布日期晚于WebText所用链接的截止日期，因此WebText中并未包含任何实际的CoQA训练问题或答案。

在LAMBADA数据集上，平均重叠率为1.2%。在重叠率超过15%的样例上，GPT-2的表现约好2个困惑度。排除所有含任何重叠的样例后重新计算指标，困惑度由8.6变为8.7，准确率则由63.2%降至62.9%。整体结果如此微小的变化，很可能是因为仅有二百分之一的样例存在显著重叠。

总体而言，我们的分析表明，WebText训练数据与特定评估数据集之间的数据重叠，为报告结果提供了小幅但持续的增益。然而，对于大多数数据集，我们并未观察到比标准训练集与测试集之间已存在的重叠更为显著的情况，正如表6所强调的那样。

理解并量化高度相似文本对性能的影响是一个重要的研究课题。诸如可扩展模糊匹配等更优的去重技术亦有助于更好地解答这些问题。目前，我们建议在构建新NLP数据集的训练与测试划分时，采用基于n元语法重叠的去重方法，作为一项关键验证步骤与合理性检查。另一种判断WebText语言模型性能是否源于记忆效应的方法，是考察其在自身预留测试集上的表现。

如图4所示，WebText的训练集与测试集性能相近，且均随模型规模增大而同步提升。这表明即使GPT-2在诸多方面仍未充分拟合WebText。

GPT-2还能撰写关于会说话独角兽被发现的新闻报道。示例见表13。

5. 相关工作

本工作的很大一部分旨在衡量在更大数据集上训练的更大语言模型的性能。这一




图4. WebText上训练的语言模型性能随模型规模的变化关系。

与Jozefowicz等 (2016) 在十亿词基准上扩展RNN语言模型的工作类似。Bajgar等 (2016) 亦曾通过从古腾堡计划构建更大训练数据集来补充标准训练数据集，从而提升儿童图书测试 (Childrens Book Test) 的结果。Hestness等 (2017) 对各类深度学习模型性能随模型容量与数据集规模变化的趋势进行了全面分析。尽管我们的实验在不同任务间噪声较大，但结果仍显示出相似趋势——该趋势适用于目标下的子任务，并延续至十亿参数以上级别。生成模型中已记录过一些有趣的习得功能，例如RNN语言模型中的单元可执行行宽追踪及引号/注释检测 (Karpathy等，

2015)。对我们工作更具启发性的是Liu等 (2018) 的观察：一个用于生成维基百科文章的模型同时也学会了跨语言翻译人名。先前研究还探索了网页文本语料库 (如iWeb语料库 (Davies, 2018)) 的替代过滤与构建方法。

针对语言任务的预训练方法已有大量研究。除引言中提及的工作外，GloVe (Pennington等, 2014) 将词向量表征学习扩展至全部Common Crawl语料。早期深度文本表征学习的重要工作之一是Skip-thought Vectors (Kiros等, 2015)。McCann等 (2017) 探讨了源自机器翻译模型的代表应用，Howard & Ruder (2018)

改进了 (Dai & Le, 2015) 基于RNN的微调方法。(Conneau等, 2017a) 研究了自然语言推理模型所学表征的迁移性能，(Subramanian等, 2018) 则探索了大规模多任务训练。

(Ramachandran等, 2016) 表明，seq2seq模型若以预训练语言模型分别作为编码器与解码器进行初始化，性能将获益。近期工作进一步证实，语言模型预训练对于困难生成任务 (如闲聊对话与基于对话的问答系统) 的微调同样有效 (Wolf等, 2019; Dinan等, 2018)。

6. 讨论

大量研究致力于学习 (Hill等, 2016)、理解 (Levy & Goldberg, 2014) 以及批判性评估 (Wieting & Kiela, 2019) 有监督与无监督预训练方法所得表征。我们的结果表明，无监督任务学习是另一项值得探索的有前景研究方向。这些发现或许有助于解释预训练技术在下游NLP任务中广受欢迎的原因——我们证明，当达到极限时，其中一种预训练技术本身便能直接习得任务执行能力，而无需监督式适配或修改。

在阅读理解任务上，GPT-2的零样本性能可与有监督基线相媲美。然而，在摘要等其他任务上，尽管其定性表现已体现任务特征，但按定量指标衡量，其性能仍属初级。该结果虽具有启发性的研究价值，但从实际应用角度看，GPT-2的零样本性能距离可用仍有相当差距。

我们已在许多经典NLP任务上研究了WebText语言模型的零样本性能，但仍存在大量可进一步评估的任务。毫无疑问，在许多实际任务中，GPT-2的表现仍不优于随机水平。即便在我们评估过的常见任务 (如问答和翻译) 中，语言模型也仅在具备足够容量时才开始超越简单基线。

尽管零样本性能确立了GPT-2在许多任务上的潜在性能基线，但微调后的性能上限尚不明确。在某些任务上，GPT-2完全抽象式的输出显著区别于当前在诸多问答及阅读理解数据集上处于领先地位的抽取式指针网络 (Vinyals等, 2015) 输出。鉴于GPT微调先前的成功经验，我们计划在decaNLP和GLUE等基准上开展微调研究，尤其因为尚不清楚额外的

GPT-2 的训练数据规模与模型容量足以克服 BERT (Devlin 等, 2018) 所展现的单向表征低效性。

7. 结论

当一个大型语言模型在足够大且多样化的数据集上训练时, 它能在众多领域和数据集上表现出色。GPT-2 在所测试的8个语言建模数据集中的7个上实现了零样本最先进性能。该模型在零样本设置下所能执行任务的多样性表明, 当高容量模型被训练以最大化足够多样化文本语料的概率时, 它们开始学会在无需显式监督的情况下执行大量出人意料的任务。5

致谢

感谢所有撰写文本、分享链接并在WebText中为内容点赞的人。数以百万计的人参与了GPT-2训练数据的创建。同时感谢所有协助我们搭建训练基础设施的谷歌员工, 包括扎克·斯通、JS·里尔、乔纳森·许、拉塞尔·鲍尔、杨龙成、诺姆·沙泽尔、所罗门·布洛斯、迈克·班菲尔德、阿曼·古普塔、丹尼尔·宋以及更多同仁。最后, 感谢对论文初稿提供反馈意见的各位: 雅各布·斯坦哈特、萨姆·鲍曼、杰弗里·欧文和麦迪逊·梅。

参考文献

阿尔-鲁富, R., 崔, D., 康斯坦特, N., 郭, M., 和琼斯, L. 使用更深层自注意力的字符级语言建模。arXiv预印本 arXiv:1808.04444, 2018。

阿尔贝蒂, C., 李, K., 和柯林斯, M. 自然问题数据集上的BERT基线。arXiv预印本 arXiv:1901.08634, 2019。

阿尔科恩, M. A., 李, Q., 龚, Z., 王, C., 麦, L., 顾, W.-S., 和阮, A. (用) 姿势出击: 神经网络极易被熟悉物体的奇异姿态所欺骗。arXiv预印本 arXiv:1811.11553, 2018。

阿莫代, D., 阿南塔纳拉亚南, S., 阿努拜, R., 白, J., 巴滕伯格, E., 凯斯, C., 卡斯珀, J., 卡坦扎罗, B., 程, Q., 陈, G. 等。Deep Speech 2: 英文与中文端到端语音识别。载于《国际机器学习会议》, 第173–182页, 2016。

阿尔泰克斯, M., 拉巴基, G., 阿吉雷, E., 和赵, K. 无监督神经机器翻译。arXiv预印本 arXiv:1710.11041, 2017。

阿尔泰克斯, M., 拉巴基, G., 和阿吉雷, E. 一种有效的无监督机器翻译方法。arXiv预印本 arXiv:1902.01313, 2019。

巴, J. L., 基罗斯, J. R., 和欣顿, G. E. 层归一化。arXiv预印本 arXiv:1607.06450, 2016。

巴日加尔, O., 卡德莱茨, R., 和克莱因迪恩斯特, J. 拥抱数据丰富性: BookTest阅读理解数据集。arXiv预印本 arXiv:1610.00956, 2016。

巴尔茨, B. 和登兹勒, J. 我们是否在测试数据上训练? 清除CIFAR中近似重复样本。arXiv预印本 arXiv:1902.00423, 2019。本吉

奥, Y., 杜夏尔姆, R., 文森特, P., 和若万, C. 一种神经概率语言模型。《机器学习研究杂志》, 3(2月):1137–1155, 2003。

鲍曼, S. R., 帕维利克, E., 格拉夫, E., 范杜尔梅, B., 王, A., 胡拉, J., 夏, P., 帕帕加里, R., 麦考伊, R. T., 帕特尔, R. 等。寻找ELMo的朋友: 超越语言建模的句子级预训练。arXiv预印本 arXiv:1812.10860, 2018。卡鲁

阿纳, R. 多任务学习。《机器学习》, 28(1):41–75, 1997。

切尔巴, C., 米科洛夫, T., 舒斯特, M., 葛, Q., 布兰茨, T., 科恩, P., 和罗宾逊, T. 用于衡量统计语言建模进展的十亿词基准。arXiv预印本 arXiv:1312.3005, 2013。

科洛贝尔, R., 韦斯顿, J., 博图, L., 卡尔伦, M., 卡武库乔格, K., 和库克萨, P. 自然语言处理 (几乎) 从零开始。《机器学习研究杂志》, 12(8月):2493–2537, 2011。

孔诺, A., 基拉, D., 施文克, H., 巴拉尔, L., 和博尔德斯, A. 基于自然语言推理数据的通用句子表征监督学习。arXiv预印本 arXiv:1705.02364, 2017a。

孔诺, A., 兰普尔, G., 兰扎托, M., 德努瓦耶, L., 和杰古, H. 无需平行数据的词翻译。arXiv预印本 arXiv:1710.04087, 2017b。

戴, A. M. 和李, Q. V. 半监督序列学习。载于《神经信息处理系统进展》, 第3079–3087页, 2015。

戴, Z., 杨, Z., 杨, Y., 科恩, W. W., 卡博内尔, J., 李, Q. V., 和萨拉赫丁诺夫, R. Transformer-XL: 超越固定长度上下文的注意力语言模型。arXiv预印本 arXiv:1901.02860, 2019。

戴维斯, M. 140亿词iWeb语料库。
<https://corpus.byu.edu/iWeb/>, 2018。

德赫加尼, M., 古斯, S., 维尼亚尔斯, O., 乌斯佐雷特, J., 和凯泽, Ł. 通用Transformer。arXiv预印本 arXiv:1807.03819, 2018。

德夫林, J., 张, M.-W., 李, K., 和图塔诺娃, K. BERT: 用于语言理解的深度双向Transformer预训练。arXiv预印本 arXiv:1810.04805, 2018。

迪南, E., 罗勒, S., 舒斯特, K., 范, A., 奥利, M., 和韦斯顿, J. 维基百科向导: 基于知识的对话代理。arXiv预印本 arXiv:1811.01241, 2018。

范, A., 刘易斯, M., 和多夫林, Y. 层次化神经故事生成。arXiv预印本 arXiv:1805.04833, 2018。

5 小型模型的初步下载与使用代码见 <https://github.com/openai/gpt-2>

芬恩, C., 阿贝勒, P., 和莱文, S. 适用于深度网络快速适应的模型无关元学习。arXiv预印本 arXiv:1703.03400, 2017。

格赫曼, S., 邓, Y., 和 拉什, A. M. 自底向上抽象式摘要。arXiv 预印本 arXiv:1808.10792, 2018。吉利克, D., 布伦

克, C., 维尼尔斯, O., 和 苏布拉马尼安, A. 多.....字节级多语言处理。arXiv 预印本 arXiv:1512.00103, 2015。

龚, C., 何, D., 谭, X., 秦, T., 王, L., 和 刘, T.-Y. Frage: 频率无关的词表征。载于《神经信息处理系统进展》, 第1341–1352页, 2018。格拉夫, E., 朱兰, A., 和 乌苏尼尔,

N. 改进神经具有连续缓存的语言模型。arXiv 预印本 arXiv:1612.04426, 2016。

何, K., 张, X., 任, S., 和 孙, J. 深度残差网络中的恒等映射。载于《欧洲计算机视觉会议》, 第630–645页。施普林格, 2016。

赫斯特尼斯, J., 纳朗, S., 阿尔达拉尼, N., 迪亚莫斯, G., 俊, H., 基安-内贾德, H., 帕特瓦里, M., 阿里, M., 杨, Y., 和 周, Y. 深度学习缩放经验上可预测。arXiv 预印本 arXiv:1712.00409, 2017。

希尔, F., 博尔德斯, A., 查普拉, S., 和 韦斯顿, J. “金发姑娘原则”: 借助显式记忆表征阅读儿童读物。arXiv 预印本 arXiv:1511.02301, 2015。

希尔, F., 乔, K., 和 科尔霍宁, A. 从未标注数据中学习句子的分布式表征。arXiv 预印本 arXiv:1602.03483, 2016。

黄, L., 威斯曼, S., 和 拉什, A. M. 实体追踪提升完形填空式阅读理解。arXiv 预印本 arXiv:1810.02891, 2018。

霍华德, J. 和 鲁德尔, S. 通用语言模型微调用于文本分类。载于《第56届计算语言学协会年会会议录》
计算语言学协会会议录 (第1卷:
长论文), 第1卷, 第328–339页, 2018。

杰利内克, F. 和 梅瑟, R. L. 从稀疏数据中对马尔可夫信源参数进行插值估计。载于《.....》会议录
实践中的模式识别研讨会, 阿姆斯特丹, 荷兰
荷兰: 北荷兰出版社, 1980年5月。

贾, R. 和 梁, P. 用于评估阅读理解系统的对抗样本。arXiv 预印本 arXiv:1707.07328, 2017。

乔泽福维奇, R., 维尼尔斯, O., 施斯特, M., 沙泽尔, N., 和 吴, Y. 探索语言建模的极限。arXiv 预印本 arXiv:1602.02410, 2016。

凯撒, L., 戈麦斯, A. N., 沙泽尔, N., 瓦斯瓦尼, A., 帕尔马, N., 琼斯, L., 和 乌斯佐雷特, J. 一个模型通学万物。arXiv 预印本 arXiv:1706.05137, 2017。

卡尔帕西, A., 约翰逊, J., 和 费-费, L. 循环网络的可视化与理解。arXiv 预印本 arXiv:1506.02078, 2015。

柯克帕特里克, J., 帕斯卡努, R., 拉比诺维茨, N., 维内斯, J., 德斯雅丁斯, G., 鲁苏, A. A., 米兰, K., 夸恩, J., 拉马略, T., 格拉布斯卡-巴温斯卡, A., 等。克服神经网络中的灾难性遗忘。《美国国家科学院院刊》, 第201611835页, 2017。

基罗斯, R., 朱, Y., 萨拉赫丁诺夫, R. R., 泽梅尔, R., 乌尔塔苏恩, R., 托拉尔巴, A., 和 菲德勒, S. 跳思向量。载于《神经信息处理系统进展》, 第3294–3302页, 2015。克里热夫斯

基, A., 苏茨克维, I., 和 辛顿, G. E. ImageNet 分类任务中的深度卷积神经网络。载于《神经信息处理系统进展》, 第1097–1105页, 2012。

奎亚特科夫斯基, T., 帕洛马克, J., 赖因哈特, O., 科林斯, M., 帕里克, A., 阿尔贝蒂, C., 埃普斯坦, D., 波洛苏欣, I., 凯尔西, M., 德夫林, J., 等。自然问题: 问答研究基准。2019。

莱克, B. M., 乌尔曼, T. D., 特南鲍姆, J. B., 和 格什曼, S. J. 构建像人类一样学习和思考的机器。《行为与脑科学》, 第40卷, 2017。

朗普尔, G., 康诺, A., 德努瓦耶, L., 和 兰扎托, M. 仅利用单语语料库的无监督机器翻译。arXiv 预印本 arXiv:1711.00043, 2017。

勒韦斯克, H., 戴维斯, E., 和 莫根斯特恩, L. 温诺格拉德模式挑战。载于《第十三届知识表示与推理原理国际会议》, 2012。

利维, O. 和 戈德堡, Y. 神经词嵌入作为隐式矩阵分解。载于《神经信息处理系统进展》, 第2177–2185页, 2014。

刘, P. J., 萨利赫, M., 波特, E., 古德里奇, B., 塞帕西, R., 凯撒, L., 和 沙泽尔, N. 通过摘要长序列生成维基百科。arXiv 预印本 arXiv:1801.10198, 2018。麦坎, B., 布拉德伯里, J.,

熊, C., 和 索切, R. 学得的.....翻译中的上下文化词向量。载于《神经信息处理系统进展》, 第6294–6305页, 2017。

麦坎, B., 凯斯卡, N. S., 熊, C., 和 索切, R. 自然语言十项全能: 以问答形式实现多任务学习。arXiv 预印本 arXiv:1806.08730, 2018。

梅里蒂, S., 熊, C., 布拉德伯里, J., 和 索切, R. 指针哨兵混合模型。arXiv 预印本 arXiv:1609.07843, 2016。米科洛夫,

T., 苏茨克维, I., 陈, K., 科拉多, G. S., 和 迪恩, J. 词与短语的分布式表征及其组合性。载于《神经信息处理系统进展》, 第3111–3119页, 2013。

纳拉帕蒂, R., 周, B., 古尔切赫雷, C., 向, B., 等。使用序列到序列RNN及其扩展方法的抽象式文本摘要。arXiv 预印本 arXiv:1602.06023, 2016。

帕佩尔诺, D., 克鲁舍夫斯基, G., 拉扎里杜, A., 范, Q. N., 伯纳迪, R., 佩佐莱, S., 巴罗尼, M., 博莱达, G., 和 费尔南德斯, R. Lambada 数据集: 需要宽泛篇章语境的词预测任务。arXiv 预印本 arXiv:1606.06031, 2016。彭宁顿, J., 索切,

R., 和 曼宁, C. Glove: 全局向量用于词表征。载于《2014年自然语言处理经验方法会议录 (EMNLP) 》, 第1532–1543页, 2014。

- 彼得斯, M. E. 和 勒科克, D. 利用多样化特征集进行内容抽取。载于《第22届国际万维网大会会议录》, 第89–90页。ACM, 2013。
- 彼得斯, M. E., 诺伊曼, M., 艾耶尔, M., 加德纳, M., 克拉克, C., 李, K., 和 泽特勒迈尔, L. 深度上下文化词表征。arXiv 预印本 arXiv:1802.05365, 2018。拉德福德, A., 乔泽福维奇, R., 和 苏茨克维, I. 学习.....
生成评论并发现情感倾向。arXiv 预印本 arXiv:1704.01444, 2017。
- 拉德福德, A., 纳拉西姆汉, K., 萨利曼斯, T., 和 苏茨克维, I. 通过生成式预训练提升语言理解能力。2018。
- 拉马钱德兰, P., 刘, P. J., 和 勒, Q. V. 序列到序列学习的无监督预训练。arXiv 预印本 arXiv:1611.02683, 2016。
- 雷希特, B., 罗尔奥夫斯, R., 施密特, L., 和 森卡尔, V. CIFAR-10 分类器能否泛化至 CIFAR-10? arXiv 预印本 arXiv:1806.00451, 2018。
- 雷迪, S., 陈, D., 和 曼宁, C. D. Coqa: 一项对话式问答挑战。arXiv 预印本 arXiv:1808.07042, 2018。
- 施瓦茨, R., 萨普, M., 孔斯塔斯, I., 齐勒斯, L., 崔, Y., 和 史密斯, N. A. 故事填空任务: 华盛顿大学自然语言处理系统。载于《.....》会议录 第二届词汇、句法与篇章层级模型关联研讨会 篇章级语义, 第52–55页, 2017。
- 西, A., 刘, P. J., 和 曼宁, C. D. 直击要点: 基于指针-生成器网络的摘要生成。arXiv 预印本 arXiv:1704.04368, 2017。
- 森什里奇, R., 哈多, B., 和 伯奇, A. 基于子词单元的稀有词神经机器翻译。arXiv 预印本 arXiv:1508.07909, 2015。
- 苏布拉马尼安, S., 特里施勒, A., 本吉奥, Y., 和 帕尔, C. J. 通过大规模多任务学习学习通用分布式句子表征。arXiv 预印本 arXiv:1804.00079, 2018。
- 苏茨克维, I., 维尼尔斯, O., 和 勒, Q. V. 基于神经网络的序列到序列学习。载于《神经信息处理系统进展》, 第3104–3112页, 2014。
- 苏茨克维, I., 乔泽福维奇, R., 格雷戈尔, K., 雷曾德, D., 利利克拉普, T., 和 维尼尔斯, O. 迈向有原则的无监督学习。arXiv 预印本 arXiv:1511.06440, 2015。
- Trichelair, P., Emami, A., Cheung, J. C. K., Trischler, A., Sule-man, K., and Diaz, F. On the evaluation of common-sense reasoning in natural language understanding. arXiv预印本 arXiv:1811.01778, 2018。
- Trinh, T. H. and Le, Q. V. A simple method for commonsense reasoning. arXiv预印本 arXiv:1806.02847, 2018. Vaswani, A.,
- Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., and Polosukhin, I. Attention is all you need. In *Advances in Neural Information Processing Systems*, pp. 5998–6008, 2017。
- Vinyals, O. and Le, Q. A neural conversational model. arXiv预印本 arXiv:1506.05869, 2015。
- Vinyals, O., Fortunato, M., and Jaitly, N. Pointer networks. In *Advances in Neural Information Processing Systems*, pp. 2692–2700, 2015。
- Wang, A., Singh, A., Michael, J., Hill, F., Levy, O., and Bow-man, S. R. Glue: A multi-task benchmark and analysis platform for natural language understanding. arXiv预印本 arXiv:1804.07461, 2018。
- Weston, J. E. Dialog-based language learning. In *Advances in Neural Information Processing Systems*, pp. 829–837, 2016。
- Wieting, J. and Kiela, D. No training required: Exploring random encoders for sentence classification. arXiv预印本 arXiv:1901.10444, 2019。
- Wolf, T., Sanh, V., Chaumond, J., and Delangue, C. Transfer-transfo: A transfer learning approach for neural network based conversational agents. arXiv预印本 arXiv:1901.08149, 2019。
- Yogatama, D., dAutume, C. d. M., Connor, J., Kocisky, T., Chrzanowski, M., Kong, L., Lazaridou, A., Ling, W., Yu, L., Dyer, C., et al. Learning and evaluating general linguistic intelligence. arXiv预印本 arXiv:1901.11373, 2019。

8 附录A：样本

8.1 模型容量

为补充图4中所示更大语言模型在WebText上困惑度提升的报告结果，表7至表11并列展示了最小WebText语言模型与GPT-2在随机未见WebText测试集文章上的补全结果。

8.2 文本记忆

我们观察到，GPT-2对数据集中高频重复的长字符串（如著名引言或演讲）存在一定程度的记忆行为。例如，当以葛底斯堡演说的首句半句为条件（该演说在WebText中约出现40次）时，GPT-2经贪婪解码（argmax decode）即可复现整篇演说。即使不截断采样，我们亦发现模型会先复制演说内容一段时间，随后才逐渐偏离，但偏离初期仍维持相似风格。通常在100–200词元内发生偏离，且一旦偏离，其输出的多样性便会明显增强。

为量化精确记忆现象在样本中出现的频率，我们以WebText测试集文章为条件生成GPT-2样本，并将其生成文本与真实补全文本的重叠率进行对比。分析结果如下所示，表明GPT-2重复训练集文本的频率低于保留文章的基线重叠率。




图5：WebText训练集八元组重叠率的累积分布函数（CDF），涵盖WebText测试集与样本（以WebText测试集为条件，采用Top-k截断随机采样， $k=40$ ）。大多数样本重叠率低于1%，其中三成样本完全无重叠；而测试集的中位数重叠率为2.6%。

8.3 多样性

表12展示了同一随机WebText测试集上下文的多个补全结果，揭示了在标准采样设置下补全结果的多样性。

8.4 转移鲁棒性

表13展示了前述关于‘会说话的独角兽’的新闻报道。我们发现该模型能够处理分布外上下文，但此类样本的整体质量普遍偏低。

上下文 (WebText 测试集)	
造型1：常规款 这套搭配是我购入这双鞋时最先构思出的造型。它宛如杰克·格兰瑟姆 (Jake Grantham) 造型的夏日版本；事实上，我的鞋色与他那双耐克Racer跑鞋的配色颇为接近！我并未选用厚重的哈里斯粗花呢夹克与牛仔衬衫，而是换上了纯棉双排扣夹克与亚麻衬衫。这两种面料（在此类配色下）绝对是夏日必备之选，因它们既能搭配深色裤装，亦能驾驭浅色裤装！如您所见，它们与深色牛仔裤及运动鞋的组合堪称完美。这是一套伪正装/学院风造型。 总体而言，这是一套极为休闲的造型，因此我选择用运动鞋来搭配。我并不赞同像《GQ》杂志常展示的那样，全身羊毛正装配运动鞋；但我完全乐于保持休闲格调，比如这套纯棉双排扣西装。休闲面料正是让运动鞋融入休闲男士正装造型的关键所在。我甚至建议用这双运动鞋搭配卡其色斜纹棉布西装或白色亚麻西装——只需记得去掉领带，或改穿T恤、Polo衫；领带配运动鞋，未免过于违和。	
小模型补全 . 造型2：高端路线 这套造型正处在潮流风暴的中心。它融合了ASICS与街头服饰（如J.Crew）的合作理念，以及J.Crew对传统休闲单品的诠释方式。如前所述，这属于平价单品，但实际价格可能不菲。若你正尝试以休闲运动鞋风格入行，这类单品无疑会带来挑战——不过这并无大碍；若想尝试价位更低同类造型，也完全无需犹豫！本款设计拥有极低的领口（这并非缺点）、略微加长的裤腿，以及一双修长裤管，整体效果恰到好处。我个人偏爱的配色为蓝灰色（这是我首选的浅白色调），或黑色（这是我所有设计中最钟爱的色彩）。一如既往，我在这家店挑选的配色，纯粹基于设计本身，与其他因素无关。若追求高端质感，我强烈向所有人推荐此款！ 造型3：高光时刻 这是我抓住机会尝试亮色搭配的一次造型。我认为所选色彩依据在于	GPT-2 补全 对我来说！ 造型2：休闲夹克 我知道有些人或许反对高领毛衣配运动鞋，但我希望忠于自我，因此选择了一件修身剪裁的高领毛衣，颜色也尽量贴近当天我最钟爱的色系。整体而言，这是一件经典款高领毛衣，毫无浮夸之处。我将鞋子换成了这双ASICS Tiger Killshots，现在想来颇感后悔。单论鞋本身，舒适度确实很高；但穿上去后，我发现自己的脚部轮廓显得略大。我倒愿意用它们搭配牛仔裤或斜纹棉布裤，却绝不会推荐单独穿着。毕竟影响因素实在太多。 造型3：连衣裙 这是我最后一次穿着ASICS Tiger Killshots鞋款的造型。此款ASICS设计更为现代、线条更趋简洁流畅。整双鞋呈现出我所能想到的最现代、最简约的风格！大量运用黑色元素，令这双运动鞋显得格外酷炫。夏天穿着它们，舒适度绝对有保障。 对我而言，搭配西装穿着运动鞋是最轻松打造优质运动鞋造型的方式。大致如此！如果

表7：随机未见上下文（顶部）及来自最小（左）与最大（右）模型的非刻意挑选补全结果。上下文长度为768个词元，其中约256个词元的段落内容已展示；补全长度为256个词元，并完整呈现。生成时采用Top-k随机采样，k=40。

上下文 (WebText 测试集) 西班牙一些最辉煌的历史景点便源自穆斯林统治时期，其中包括：科尔多瓦清真寺（即‘科尔多瓦大清真寺’，今称‘科尔多瓦主教座堂’）、同样位于科尔多瓦的麦地那-阿扎哈拉宫（今仅存遗址，但仍可参观，原名‘麦地那-阿兹哈尔’，即‘安达卢斯宫殿’），以及格拉纳达的阿尔罕布拉宫——一座壮丽而保存完好的宫殿。此外，西班牙现存两座建于穆斯林统治时期的犹太会堂：托莱多的圣玛丽亚拉布朗卡犹太会堂，以及科尔多瓦老城区内的科尔多瓦犹太会堂。 收复失地运动与帝国时代 [编辑]	
小模型补全 穆斯林统治下的西班牙时代，与其他地区迥然不同，拥有相当漫长的中世纪历史。尽管西班牙帝国存在于公元前9世纪下半叶，但至公元1150年，它已缓慢演变为一个规模较小、世俗化程度更高的帝国，且整体上更为繁荣、多元。公元1050年，那不勒斯皇帝——至少在部分特征上——体现为一系列从西北海岸延伸至该地区西海岸的战争与入侵（例如沿多瑙河展开的军事行动，其战线一度自直布罗陀延伸至西班牙南部，却在同日即遭罗马军队迅速摧毁）——正式采用了‘那不勒斯皇帝’这一头衔。他在过去数十年间为重建与维系帝国作出了巨大贡献，其中首项举措即面向西方。其继任者为斐迪南，他于1148年自教皇宝座夺取权力；而首位帝国继承人则是瑞典国王阿尔弗雷德二世。帝国再度成为欧洲大陆上为数不多的独立国家之一；尽管此时期其疆域内人口从未超过两亿，但民众对皇帝的话语权却十分显著。自1720年起，穆斯林人口已占西班牙总人口的一半。	GPT-2 补全 1092年与1095年的‘收复失地运动’（字面意为‘重返故土’）见证了伊比利亚半岛上卡斯蒂利亚与阿拉贡联合王国的建立，其间仍存续着一个穆斯林王朝。这是欧洲历史上最后一次将穆斯林统治视为本土政权，也是基督教势力煽动并组织起来的冲突最后一次在欧洲大规模显现。 穆斯林摩尔人在西班牙的统治时期，常被（尤其在非穆斯林群体中）称为‘格拉纳达征服’，而西班牙有时亦被称作‘格拉纳达的西班牙’。穆斯林统治的最后几年之后，西班牙开启了‘收复失地运动’（Reconquista），穆斯林或遭驱逐、或被迫离开伊比利亚半岛——这一进程以斐迪南九世于1189年3月普瓦捷战役的胜利及萨拉丁于1187年攻占耶路撒冷为标志。 西班牙收复失地运动时期结束时，摩尔人撤退至北方。然而，摩尔人统治并未完全被基督教统治取代，直至收复失地运动再度展开；该运动持续时间为1229年至1492年。 西班牙最后一个穆斯林政权——格拉纳达——被

表 8：随机未见过的上下文（上方），以及来自最小（左侧）和最大（右侧）模型的非刻意挑选补全结果。上下文长度为 768 个词元，其中约 256 个词元的段落已展示；补全结果长度为 256 个词元，且全部完整显示。生成时采用 Top-k 随机采样，k = 40。

上下文 (WebText 测试) 粉红幽灵的人工智能设计思路与红色幽灵的行为恰好相反。粉红幽灵实际试图抢在吃豆人前方拦截。其实现方式是：将目标设定为吃豆人当前位置沿其行进方向再向前四格的位置。唯一例外是当吃豆人向上移动时：由于代码中存在溢出错误，该计算会额外引入一个等于预期向上偏移量的向左偏移。 利用吃豆人预期位置这一特性，玩家可针对粉红幽灵的导航代码加以利用。这种情况最常见于吃豆人与粉红幽灵彼此靠近之时。例如，当二者相向而行且间距小于四格时，目标格便落在粉红幽灵身后。若粉红幽灵在此状态下遭遇岔路口，便会尝试折返（即转向）以抵达目标格。玩家常会实施一种被称为‘假动作’的操作：即在粉红幽灵接近岔路口时迅速改变方向，借此恰在粉红幽灵计算目标格的瞬间使其偏移。	
小型模型补全 自左方而来时，他们便能得到正确的方向。 若该位置实际上距离吃豆人更远，则玩家不会响应幽灵的移动，幽灵反而会返回玩家当前位置。这是因为吃豆人的移动并非靠转向实现。 幽灵需前往某处其他地点，方可返回起始位置，而实现方式多种多样。它通常只是直接离开当前位置；例如，若吃豆人从悬崖跳下，便会回到其消失前所在的位置。此类幽灵路径的可能性相当丰富，但最明显的情形是：玩家希望避免陷入游戏困境，目标可能仅仅是让吃豆人在游戏中存活的时间达到其原本存活时长的三分之一。 追逐 就吃豆人而言，这类似于吃豆人在战斗中追赶对手的情形。 幽灵可穿越敌人进行追逐。这出于多种原因，对吃豆人及其人工智能均有用处。与大多数幽灵游戏不同，此幽灵仅沿某一方向行进，	GPT-2 补全 即将穿过路口时，吃豆人便能躲开幽灵发射的弹丸，并回到安全屋这一安全位置。 巴斯特 黄色幽灵的人工智能专门设计为尽量阻止吃豆人离开安全屋。玩家需按下空格键打开安全屋的门，然后进入其中，在下一个房间找到藏匿的黄色幽灵。 玩家还需注意：若幽灵发现吃豆人已在安全屋内，则不会尝试离开安全屋。事实上，除非幽灵本身已在安全屋内，否则它根本不会尝试离开。 这两种行为基于一个事实：玩家并不总是在吃豆人（或布鲁蒂）之前试图抵达安全屋。 若一名幽灵（或另一名玩家）已身处安全屋内，并试图在吃豆人（或布鲁蒂）离开后立即冲出，则玩家也须警惕这一漏洞。此时，该幽灵将以类似追逐模式的方式尝试离开安全屋。 吃豆人 有一些幽灵会追捕吃豆人。这些幽灵是

表 9：随机未见过的上下文（上方），以及来自最小（左侧）和最大（右侧）模型的非刻意挑选补全结果。上下文长度为 768 个词元，其中约 256 个词元的段落已展示；补全结果长度为 256 个词元，且全部完整显示。生成时采用 Top-k 随机采样，k = 40。

上下文 (WebText 测试) 迈克尔·P·戈尔丁下士入伍前是一名来自爱尔兰的非技术劳工，于 1860 年 11 月加入 A 连。戈尔丁幸存至战争结束。帕特里克·奥尼尔下士同样来自爱尔兰，最早于 1854 年入伍，曾在俄勒冈州服役于第 3 美国炮兵团 L 连。之后他返回东海岸，并于 1860 年加入该连队。奥尼尔服役至 1874 年，后被任命为纽约威尔莱茨角国家公墓主管。本杰明·布朗下士是一名来自纽约州奥兰治县的鞋匠。1862 年 8 月，他加入新组建的第 124 纽约志愿军，并于同年 10 月成为六十一人之一转入 A 连。布朗于 1864 年 2 月在布兰迪站营地期间重新入伍。1867 年服役期满后，他回归平民生活。 6 月 10 日，军械士威廉·柯林斯晋升为下士，此举很可能是为了填补詹姆斯河渡河作战所需的战斗领导空缺。柯林斯的服役记录并未体现他获得此次晋升所展现出的素质，但他显然已克服了一些严重问题。他出生于纽约州萨克茨港，于 1853 年 12 月年满二十二岁时加入该连队，并于 1858 年 12 月再次入伍。就在 1861 年 4 月战争爆发前一个月，柯林斯擅离职守，三年后才被抓获。他于 1864 年 3 月 22 日重返连队，随后受审，	
小型模型补全 因军事指控被开除出美国军队。他重返原部队，并在内战期间被分配至内部事务处。 作为一名工程师，柯林斯也在其家乡纽约接受过工程学训练。在联合学院工程系完成研究生学业后，他同时在美国陆军服役两年。在此期间，他在丹尼尔·普菲弗上尉麾下工作，并于 1870 年 5 月晋升为上校——这比普菲弗上尉入伍晚三年。柯林斯在第一师完成首年服役后返回英国，随后又在工兵部队服役两年；至第二年时，他开始履行其服役职责。 j—endoftext—{莫斯科，7 月 5 日 (路透社)——据总部位于英国的俄罗斯官方媒体、政府消息源及专家称，莫斯科方面试图淡化叙利亚反对派军事集结的严重性，同时继续支持唐纳德·特朗普总统修建美墨边境墙的计划，并将其称为一场军事政变。 美国主导的叙利亚战争老兵兼美国叙利亚事务特使迈克尔·弗林 (R)，右，正与常驻美国的叙利亚政治分析人士艾哈迈德·科里亚特交谈，	GPT-2 补全 同年 6 月。因逃兵罪被判处枪决，但他仍继续服现役。 詹姆斯·J·达尔船长于 1829 年出生于弗吉尼亚州，正值革命时期；他于 1836 年随父亲加入陆军。他服役于第 2 弗吉尼亚步兵团直至 1845 年，随后转入西部储备团；退伍后，他又重新加入第 25 纽约志愿军第 1 连 (该连队于 1845 年编制约为 4500 人)。他的一位兄弟詹姆斯，亦在同一旅同一连队中担任相同职务。该团于 1846 年驻扎在康涅狄格州期间，达尔船长曾多次在第 1 连服役，直至退伍。作为墨西哥战争的老兵，他曾于圣安东尼奥在约翰·J·沙利文准将的参谋部服役两年。在 1863 年的半岛战役中，他指挥一支由二十三人组成的连队，并负责统辖五十四门重型迫击炮及炮艇“平塔号” (Pinta) 所属的炮兵连，该连还配有若干其他船只。1865 年秋季，达尔船长在第 1 连服现役；两年后，他晋升为少尉。 约翰·A·奥船长

表 10：随机未见过的上下文（上方），以及来自最小（左侧）和最大（右侧）模型的非刻意挑选补全结果。上下文长度为 768 个词元，其中约 256 个词元的段落已展示；补全结果长度为 256 个词元，且全部完整显示。生成时采用 Top-k 随机采样，k = 40。

上下文 (WebText 测试)	
Xmonad、Xresources 与字体 Xresources 可能令人非常头疼 (对我而言确实如此)。因此, 以下内容或许能帮上一点忙: 首先, Xmonad 中处理字体的一般方式是通过 XFT。Xft 是 X FreeType 接口库, 负责在 Xmonad/urxvt 中实际渲染字体 (Xresources 向 X 窗口管理器下启动的程序提供一系列资源设置; 各程序的具体配置则以如下形式写入 Xresources: Urxvt.background:此处填写背景设置)。 无论如何, Xresources 中设置字体所采用的正是这种语法: urxvt*font:xft:此处填写字体名称:size=此处填写字号,xft:此处填写备用字体1。因此, 以上即为通过 Xresources 文件为 urxvt 指定字体时最基础的语法。 修复 Cygwin 中 ~/.ssh/ 目录的权限问题 在 Windows 上的 Cygwin 环境中, 我发现无法将 ~/.ssh/ 目录的权限设为 0600 (这是 SSH 允许使用密钥所必需的权限)。我遇到的症状是: 无论我如何操作, 系统总会自动修改该目录的所有者和所属组。	
小型模型补全 被设为 ~/.ssh/, 这正是原本的设定方式。此问题无法彻底解决。我发现只需用鼠标点击输入用户名, 再尝试将组权限设为 0600, 即可大幅改善使用体验——这正是我当前系统的配置方式。 然而, 就我当前使用的 Linux 版 Cygwin 7 而言, 此操作已完全不必要! 我还安装了一个名为 chroot 的软件包, 它可通过允许你向系统目录安装/升级来实现该功能。 因此, 自 Windows 8 起, 安装该组件可能需要 chroot 操作。我反复尝试后发现, 在 Linux 上安装再卸载, 其实并不麻烦。据我上次关于 Cygwin 的记录, 该脚本本身即可完成任务 (sudo 命令负责其余部分); 若你尝试, 需自行记录变更日志。 若这还不够令人困惑, 以下便是我尝试的做法: 我回到 ~/.ssh 目录并再次运行 chroot 脚本。结果发现, 自己最终真的遇到了权限不足问题 (因为我忘了在文件系统中为 ssh 创建符号链接, 且	GPT-2补全 , 使这些文件变为只读。我曾尝试直接启动 ssh, 并使用 passwd 等程序修改所有者/组权限至 0644, 但未奏效。虽令人困扰, 却远不如可能发生的状况严重——只是需要反复调整权限而已。 因此我决定采取相反操作: 对 Cygwin 目录下的每个 .ssh 文件夹, 将其内所有文件与子目录的权限均设为 2644。然后运行: ssh-add ~/.ssh/ 首次连接时, 你 Cygwin 环境下的 ~/.ssh 文件夹权限会被设为 0600。此后每次重新连接, 权限又会自动变为 0644。 用于 ~/.xsessionrc 中的 Xresources 的 Makefile。 这些设置写在我的 .xsessionrc 文件中: .xprofile: .xsession-errors: color= 例如: .xprofile: color=blue 由于颜色信息存储在独立文件中, 你的 ~/.xsession-errors 文件中显示的颜色会呈现为青色而非蓝色。这主要是因为目前仅有颜色本身被分配给你的

表11: 随机选取的未见上下文 (上方), 以及来自最小 (左) 与最大 (右) 两种模型的非刻意筛选补全文本。上下文长度为 768 个词元, 其中约 256 个词元的段落内容已展示; 补全文本长度为 256 个词元, 全部完整呈现。生成时采用 Top-k 随机采样, k 值设为 40。

背景 (WebText测试集)		
亚伦钟爱薄荷巧克力蛋糕，但他坚持必须搭配迷你巧克力豆，因此我将一些巧克力豆夹在蛋糕层之间。手头恰好还有几块薄荷乔乔糖，我将其压碎后一同加入，又添了些压碎的蛋白霜饼干——何乐而不为呢？这简直是一场薄荷味、巧克力味、酥脆饼干口感的盛宴。我没称量每种装饰料的具体用量，但尝过成品后，真后悔没多加些。你可以随意添加任何喜欢的配料——压碎的拐杖糖、薄荷树皮等。别吝啬用量，口感越丰富越好。 若没有7英寸蛋糕模，你可用此配方做出3个较矮的8英寸蛋糕层。		
GPT-2补全1 食谱。我做了较长版本的蛋糕，然后用同一模具制作了一层奶油霜，并将其中三分之一冷藏备用，作为蛋糕顶部的装饰霜。只需确保你在制作蛋糕前已提前备好全部奶油霜，这样便无需等待蛋清在搅拌盆底部静置。 你希望将蛋清打发至硬性发泡？那就把盛蛋糕糊的容器置于一锅微沸的水上，加热至容器仅微微温热即可。整个过程只需3-5分钟，仅需足够启动打发即可。	GPT-2补全2 食谱。倘若你照做，并且懂得如何制作这款蛋糕，那么你的生活将从此不同。 我在处理饼干碎或巧克力豆时，只遵守两条极简原则：1) 购买生糖后，须待其冷却，并确保表面至少附着半茶匙糖分，才可使用——这是我的铁律；2) 若某食谱明确要求某种原料，而我想在制作中使用它，则绝不会在线随意替换为其他材料。比如这样。 我找到一张非常可爱的卡片，上面印着几只可爱的小猫，	GPT-2补全3 食谱，预计成品量大致相当。巧克力酪乳蛋糕（打印版）：巧克力蛋糕块浸润于酪乳之中，撒上酥脆的巧克力碎，再淋上巧克力酱。做法简单，却为传统巧克力蛋糕带来清新变化！作者：妈妈自制；原料：巧克力酪乳蛋糕用料：1 1/2杯无盐黄油（室温） 1 1/2杯白砂糖 3个大鸡蛋加1个蛋黄；巧克力淋面用料：1/3杯可可粉 1 3/4杯糖粉，6盎司半甜巧克力
GPT-2补全4 食谱。 蛋白霜饼干 1 3/4杯软化黄油，1杯糖 1个蛋黄 3汤匙高脂奶油，3 1/2-4杯面粉，一小撮盐；薄荷乔乔装饰料：1 1/4杯糖粉，1杯切碎的美洲山核桃 1/2杯切碎的新鲜薄荷叶（约1/2张薄荷叶） 1茶匙薄荷精，1/4茶匙海盐 一小撮海盐	GPT-2补全5 食谱。 圣诞节清晨我的两次失败，并非源于糟糕的抹面技巧——那反而是另一段成功故事。蛋糕湿润可口，整体外观也极为漂亮。虽然它内部气孔极少、水分也不多，但巧克力与薄荷却完美融合在一起。 有一件事让我略感尴尬：所有那些配料——蛋黄、糖、融化的黄油、巧克力豆、融化的巧克力和薄荷——都必须直接混入蛋糕糊中，这极其耗时。一位朋友建议，如果我把蛋糕糊倒入另一个碗中，我	GPT-2补全6 食谱，可制作约6-9份美味的巧克力蛋糕。为防止各层蛋糕粘连，我使用了一个8英寸圆形挞模，内铺烘焙纸，再从中切出4个7英寸圆形蛋糕胚，并将它们层层叠放（此法同样适用于单层巧克力蛋糕）。准备烘烤此蛋糕时，请先移除烘焙纸，将烤箱预热至350华氏度（约177摄氏度），烘烤约30-40分钟，直至表面呈金黄色，且牙签插入后拔出干净。 巧克力酪乳分层蛋糕配薄荷乔乔

表12：基于相同上下文（源自WebText测试集）由GPT-2生成的非刻意筛选补全文本。上下文长度为384个词元（此处显示已截断），生成文本长度为128个词元。生成时采用Top-k随机采样，k值设为40。

背景（人工撰写）：一项令人震惊的发现表明，科学家在安第斯山脉一处偏远且此前未被勘探过的山谷中，发现了一群独角兽。更令研究人员惊讶的是，这些独角兽能讲一口流利的英语。
GPT-2：科学家根据其独特的角，将该种群命名为奥维德独角兽。这种四角、银白色的独角兽此前在科学界从未被发现过。 如今，经过近两个世纪，这一奇特现象背后的成因之谜终于得以解开。 拉巴斯大学（University of La Paz）进化生物学家豪尔赫·佩雷斯博士（Dr. Jorge Pérez）与数名同伴在安第斯山脉考察期间，发现了一处杳无人烟、亦无其他动物踪迹的小型山谷。佩雷斯注意到，山谷中央似有一处天然喷泉，两侧环绕着两座岩石山峰，山顶覆盖着银白色的积雪。 随后，佩雷斯等人继续深入山谷。“当我们登上其中一座山峰之巅时，水面泛着蓝色，顶部还覆盖着一些水晶。”佩雷斯说道。 佩雷斯及其同伴惊讶地目睹了一群独角兽。这些生物从空中即可清晰看见，无需大幅移动便可近距离观察——它们近得几乎能触碰到角。 科学家在考察这些奇异生物时发现，它们还能讲一口相当标准的英语。佩雷斯表示：“例如，我们观察到它们拥有一种通用语言——某种类似方言或辩证变体的语言。” 佩雷斯博士认为，独角兽可能起源于阿根廷——当地传说中，这些动物是人类抵达南美这片区域之前即已生活于此的某个失落族群的后裔。 尽管其起源仍不明朗，但有人认为，这些生物或许诞生于人类文明出现之前，当时一名人类与一只独角兽偶然相遇。据佩雷斯称：“在南美洲，此类事件似乎颇为常见。” 然而，佩雷斯（Pérez）也指出，要确凿证实独角兽实为某失落外星种族后裔，DNA检测或许是唯一途径。但它们似乎能相当流利地使用英语交流——我认为这标志着进化，或至少表明其社会组织方式发生了改变。”这位科学家表示。

表13：GPT-2在分布外语境下的条件生成结果。从中精选10个k=40时生成的样本。

原文：约3.6万年前，史前人类在今法国境内一处粗糙石灰岩洞穴壁上勾勒出种类繁多的史前巨兽。 如今，在尖端科技助力下，肖维-蓬达尔克洞穴（Chauvet-Pont-d'Arc Cave）内的这些艺术杰作已被完整复刻，成就了全球规模最大的洞穴复制品。 这座人造洞穴名为蓬达尔克洞穴（Caverne du Pont-d'Arc），建于法国南部瓦隆-蓬达尔克原址数英里之外，内含1000幅精心复刻的壁画，以及约450件骨骼及其他特征性遗存…… 约3.6万年前，史前人类在今法国境内一处粗糙石灰岩洞穴壁上勾勒出种类繁多的史前巨兽；如今，一座复刻洞穴（如图所示）已由此建成。 ...	
GPT-2 译文：位于法国南部瓦隆-蓬达尔克（Vallon-Pont-Darc）的原址是一处联合国教科文组织世界遗产，也是迄今已知最古老、保存最完好的人类装饰洞穴。复刻洞穴建于法国南部瓦隆-蓬达尔克原址数英里之外。洞穴内绘有14种不同动物形象，包括披毛犀、猛犸象与大型猫科动物。	参考译文：该洞穴仿照法国著名的蓬达尔克洞穴（Caverne du Pont-d'Arc）建造，后者是人类最早装饰且保存最完好的洞穴。复刻洞穴完整再现了全部1000幅壁画，其中包括425幅动物形象，如披毛犀与猛犸象。借助3D建模与变形投影等技术（常用于宽银幕影像拍摄），连最细微的细节均被精准复制。这座现代洞穴还复刻了熊掌印、骨骼及其他在原洞中保存下来的细节。
原文：“如果你能找到我的潜艇，它就归你了。”俄罗斯石油大亨罗曼·阿布拉莫维奇（Roman Abramovich）曾如此说道。看来，这位俄罗斯寡头兼切尔西足球俱乐部老板也不例外——他的3亿英镑超级游艇“日食号”（Eclipse）所附带的额外配置之一，正是这艘潜艇（完美适用于悄无声息登陆海岸）。 海洋素有“地球真正的最后边疆”之称，至今仍鲜为人知；亿万富翁们争相抢购各类潜航器，只为一睹世界海洋壮丽海景与奇妙生灵的真容。 因此，倘若你银行账户里尚有数百万英镑闲钱，又想拍些令所有人艳羡不已的假日照片和Instagram帖子，或许该赶紧入手一艘这样的潜艇…… 畅享鲸趣时光：OrcaSub潜艇搭载两个加压有机玻璃观景穹顶，可带你潜入海面以下2000英尺深处，尽享极致探索体验。 ...	
GPT-2 译文：U-Boat Worx潜艇可下潜至984英尺（300米）深度，具备抵达海底的能力。它可用于潜水、浮潜，甚至水肺浮潜。该潜艇还配备了浮潜平台。	参考译文：乘坐最先进的潜航器深入海洋，你将化身詹姆斯·邦德式的超级反派。部分潜航器可由游艇变形而成，另一些则可分离以实现高速探秘。奥利弗旅行公司（Olivers Travels）为其潜艇提供“深海一英里”（Mile Low）套餐，配备主厨与管家，每晚收费17.5万英镑。
原文：阿米娜·阿里·卡西姆正坐在也门比里姆岛（Birim）一座村庄清真寺内，怀里抱着她最小的孙女，用头巾擦拭泪水。这个婴儿才几个月大，当空袭初起的那个夜晚，卡西姆曾拼命捂住她的耳朵。她说，自己彻夜未眠，躺在清真寺里，一边听着婴儿啼哭，一边数着爆炸声。 不过情况本可能更糟——他们本可能仍待在家中，第一枚导弹就已落下。我们的邻居朝我丈夫大喊：‘你们必须立刻离开，他们来了！’我们拔腿就跑。刚一离开屋子，第一枚导弹便落在屋旁，紧接着第二枚直接命中房屋，整栋建筑被夷为平地。”卡西姆向我们讲述道……	
GPT-2 译文：也门正处于内战之中。沙特阿拉伯正领导联军开展空袭行动，目前已持续轰炸也门两个多月。	参考译文：阿米娜·阿里·卡西姆（Amina Ali Qassim）一家在逃离也门前曾躲进一座清真寺避难。成千上万像他们一样的人正登上船只驶往吉布提。沙特阿拉伯为击败胡塞武装分子，持续对也门发动空袭。

表14：GPT-2 在CNN与《每日邮报》数据集测试集上生成的摘要与参考摘要对比。

英文参考译文 此次再版名为《The Next Day Extra》，以三张光盘形式呈现：原专辑、未公开的录音室现场专辑及混音版，并附一张DVD，内含此前已发布的四支音乐短片。	GPT-2 法语翻译 此次再版以首张光盘形式发行，包含专辑本体、录音室现场专辑与混音版，另附一张DVD，其中收录数支此前已发布的音乐短片。
法文参考译文 一名男子解释称，他此前已识别出功能性疝气的症状；而我成功完成了该功能性疝气的治疗，我成功了。	GPT-2 英文翻译 此次发行最初以三张光盘形式推出：原专辑、未公开的录音室现场专辑及混音版，另附一张DVD，内含前一日发布的四支音乐短片。
英文参考译文 一名男子解释称，他此前接受的免费疝气手术将使他能够重新工作。	GPT-2 法语翻译 一名男子解释称，他此前已识别出功能性疝气的症状；而我成功完成了该功能性疝气的治疗，我成功了。
法文参考译文 一名男子表示，他此前接受的免费疝气手术将使他能够重新工作。	GPT-2 英文翻译 一名男子告诉我，他原本承诺可获得的手术津贴不足以支撑他出行。
英文参考译文 克里先生通过视频连线在伦敦一场开放政府会议上发表讲话时表示：“毫无疑问，总统、我和政府其他人士确实了解到一些事情一直在自动运行——这种能力自第二次世界大战以来便已存在，历经冷战那段极其艰难的岁月，再到‘9·11’事件。”	GPT-2 法语翻译 首届国际在线视频会议期间，国际出版部部长通过视频连线发言称：“目前仅有一个问题显而易见，即总统与我，以及所有其他行政人员，均曾在战争时期、冷战时期，乃至此后特定历史阶段，就相关事务作出明确决断。”
法文参考译文 克里先生通过视频连线方式出席在伦敦举行的政府间会议时指出：“无可否认，总统本人、我以及其他政府成员，自第二次世界大战起，历经冷战艰难岁月，直至‘9·11’事件之后，都曾借助自动化手段开展若干工作，这已成为一种既成事实。”	GPT-2英文翻译 在美国与伦敦举行的一场视频会议上，美国国务卿约翰·克里表示：“无可否认，总统本人、我以及政府其他成员，早已知晓过去为实现某些自动化操作而作出的若干决策。”

表15. GPT-2生成的英译法与法译英示例。

上下文（段落及此前的问题/回答对）

2008年夏季奥运会火炬接力活动自2008年3月24日开始，至8月8日结束，旨在为2008年夏季奥运会预热，其主题为“同一个世界，同一个梦想”。火炬接力计划于2007年4月26日在中国北京正式公布。本次接力活动亦被主办方称为“和谐之旅”，历时129天，火炬传递总里程达137,000公里（约85,000英里），创下了自1936年夏季奥运会开创火炬接力传统以来的最长纪录。

奥运圣火于3月24日在希腊奥林匹亚——奥林匹克运动会发源地点燃后，先抵达雅典的帕纳辛奈科体育场，随后前往北京，并于3月31日抵达。自北京出发，圣火传递路线遍及六大洲。火炬途经丝绸之路沿线城市，象征着古代中国与世界其他地区的联系。此次火炬传递还包括一项特殊环节：圣火经由中国一侧登上位于尼泊尔与中国西藏边境的珠穆朗玛峰顶峰，为此活动，该区域特地临时关闭。

问：主题是什么？

答：同一个世界，同一个梦想。

问：比赛全长多少？答：
137,000公里

问：本届赛事规模是否大于往届？答：否

问：比赛从哪里开始？
答：希腊奥林匹亚

问：那个地方有什么特别之处吗？答：奥林匹克运动会的发源地

问：之后他们去了哪里？
答：雅典

问：比赛持续了多少天？
答：七天

问：他们参观过哪些著名地标？答：
帕纳辛奈科体育场

问：他们还攀登过其他山峰吗？
答：

模型回答：珠穆朗玛峰

众包工作者回答：未知，是，是，是

表16. CoQA部分问答示例。

上下文（段落及此前的问题/回答对）

汤姆始终陪伴在54岁的秘书凯瑟琳·格林身边。他在凯瑟琳的办公室里自由走动，也随她一同外出购物。
“大多数人似乎并不介意汤姆”，凯瑟琳说，她认为汤姆非常棒。“他是我的第四个孩子”，她这样说道。她或许真将汤姆视作自己的儿子，并以对待儿子的方式对待他。汤姆自行采购食物、支付医疗账单和税费——但实际上，汤姆是一条狗。

凯瑟琳与汤姆生活在瑞典。这是一个由政府制定各项规章、要求全民依规有序生活的国家，同时政府也为国民提供高水平的福利保障。而这种高水准的保障需要大量资金支持。

瑞典民众对各类消费均需缴税习以为常，因此对于养狗亦需额外缴税一事并不感到意外。部分民众每年为获得养狗许可所缴纳的税费高达500瑞典克朗，这笔资金由政府用于建设犬类医院，有时也用于治疗患病犬只。然而，此类治疗费用通常十分高昂，因此许多主人选择为爱犬购买健康保险甚至生命保险。

在瑞典，狗主人须为其犬只造成的任何损害承担赔偿责任。瑞典养犬俱乐部的一名官员对此解释道：倘若您的狗跑上马路并被过往车辆撞伤，作为主人，您须赔偿该车辆所受的全部损失，即便您的狗已在事故中死亡。

问：凯瑟琳多大年纪？

答：54

问：她住在哪儿？

答：

模型回答：斯德哥尔摩

众包工作者回答：瑞典，瑞典，在瑞典，瑞典

表17. CoQA部分问答示例。